

Tarea 1: Predicción de resultados del fútbol uruguayo

Este laboratorio tiene por objetivos:

- a) Aplicar herramientas metodológicas sobre datos reales.
- b) Implementar y aplicar métodos de aprendizaje supervisado para predecir resultados de partidos de fútbol.
- c) Analizar los resultados obtenidos.

Problema

El problema a resolver es el de predecir el resultado de un partido de fútbol, con tres valores posibles: gana el local, gana el visitante, o hay empate. Para ello, utilizaremos el conjunto de datos construido por David Schoch¹ de resultados de partidos de diferentes ligas, restringido a los partidos del fútbol uruguayo entre 1932 y 2025.

1 – Preprocesamiento

Aplique herramientas adecuadas sobre el dataset provisto para limpiar los datos, completar valores faltantes, realizar transformaciones y discretizaciones, eliminar duplicados y cualquier otro procedimiento que entienda necesario.

Investigue y pruebe distintas formas de utilizar los datos disponibles. No es obligatorio usar todos los atributos y puede crear nuevos atributos calculados, o incluso agregar atributos provenientes de fuentes externas.

Construya un pipeline de procesamiento completamente reproducible. Se recomienda utilizar la clase Pipeline de scikit-learn para esta tarea.

2 - Modelos supervisados

Implemente clasificadores supervisados para predecir la clase objetivo ganador, que debe agregarse al conjunto de datos y puede tomar los valores 'L' (cuando gana el local), 'V' (cuando gana el visitante) y 'E' (cuando hay empate):

- i) **Árbol de decisión:** con un hiperparámetro `min_info_gain` que detenga la recursión cuando ningún atributo supere una ganancia mínima de información.
- ii) **Naive Bayes:** con el hiperparámetro `m`, tamaño equivalente de muestra.

Para la experimentación, utilice, además, las implementaciones de scikit-learn de los métodos de clasificación Random Forest y Naive Bayes.

Además, debe implementar un clasificador base que siempre prediga que gana el equipo que tiene una mayor proporción de partidos ganados en general en los últimos diez años.

¹<https://github.com/schochastics/football-data/tree/master>

3 – Experimentación

Divida el conjunto de datos en subconjuntos de entrenamiento y evaluación. Para ello considere como conjunto de entrenamiento los partidos jugados hasta el año 2023 inclusive y como conjunto de evaluación los partidos jugados en 2024 y 2025.

Ajuste los hiperparámetros solicitados (y eventualmente otros que quiera investigar) utilizando validación cruzada. Al tratarse de datos temporales, debe prestar especial atención a la partición de conjuntos utilizada. Investigue cómo realizar la partición en estos casos y utilice un método adecuado para su implementación. Compare el desempeño de cada clasificador –tanto los suyos como los provistos por scikit-learn–, graficando el error al modificar los hiperparámetros definidos en la sección anterior.

Una vez obtenidos los mejores hiperparámetros para cada método, entrene nuevamente los clasificadores sobre el conjunto de entrenamiento, y evalúe sobre el conjunto de evaluación. Para la evaluación, utilice las medidas de precisión, recall, F1 por clase, accuracy y macro-F1. Presente la matriz de confusión obtenida y analice los resultados, incluyendo un breve análisis cualitativo para alguno de los modelos, sobre, por ejemplo, en qué escenarios funciona mejor y en cuáles tiende a equivocarse.

Entregables

1. Código de las implementaciones solicitadas.
2. Jupyter Notebook que lea el conjunto de datos, entrene los modelos y muestre su funcionamiento clasificando instancias².
3. Informe con las pruebas realizadas y los resultados obtenidos. El informe a entregar es un artículo en formato IEEE³ de no más de 5 páginas.

Implementación

Utilice Python 3.12 y scikit-learn 1.9. Fije las semillas aleatorias. Se permite usar bibliotecas para manipulación de datos, métricas y visualización.

Fecha límite de entrega

Lunes 21 de septiembre de 2026, a las 23:59.

Respecto al uso de IA

Siguiendo las pautas de de la [Guía para el uso ético y crítico de inteligencia artificial](#) en las unidades curriculares de Facultad de Ingeniería, este curso habilita su uso extensivo (categoría 3): "Se espera el uso de la IA como herramienta profesional, manteniendo un uso crítico y un entendimiento profundo de sus implicaciones éticas (p. ej., declarar su uso) y técnicas (p. ej., juzgar sus resultados)". Revise ese documento y, ante cualquier duda, comuníquese con el equipo docente antes de enviar su trabajo

Más allá de lo normativo, es importante que implemente a conciencia la tarea pedida; si genera código con AI sepa qué es lo que está generando, dado que es la forma de entender e incorporar los conocimientos adquiridos. En todo caso, el código generado deberá ser fácil de entender, incluyendo comentarios y otras buenas prácticas de programación.

² La solución tiene que ser autocontenida: no se aceptarán archivos de procesamiento parciales como parte de la entrega.

³ <https://www.ieee.org/conferences/publishing/templates>